

Exercice technique – Fiabilisation d'un catalogue produit

Durée : 30 minutes

Contexte

ULTY intègre les catalogues produits de différents magasins afin d'alimenter un référentiel produit unique.

Chaque magasin met quotidiennement à disposition un fichier CSV nommé `store_listing_produit.csv`, utilisé comme source de données pour les différents services de la plateforme.

Avant son intégration, ce fichier doit être contrôlé, fiabilisé et, lorsque cela est pertinent, enrichi de manière automatisée.

Le fichier fourni contient environ **10 000 produits**.

Contexte fonctionnel

Chaque produit est décrit par les champs suivants :

- id_produit
- ean
- nom
- url_image
- taxonomie (jusqu'à 4 niveaux)
- tva

Le jeu de données contient volontairement :

- des anomalies techniques (format, encodage, URL...);
- des incohérences entre plusieurs champs ;
- des libellés caisse ou fortement abrégés ;
- des doublons ou produits similaires ;
- des données nécessitant une interprétation métier.

Travail demandé

Décrivez le processus que vous mettriez en place afin de fiabiliser automatiquement ce catalogue avant son intégration dans ULTY.

Vous pouvez répondre sous la forme :

- d'un schéma d'architecture ;
- ou de quelques paragraphes.

Expliquez notamment :

- les principales étapes du pipeline de traitement ;
- les contrôles que vous mettriez en œuvre ;
- quelles anomalies peuvent être corrigées automatiquement ;
- dans quels cas un LLM pourrait apporter de la valeur ;
- quels cas devraient être soumis à une validation humaine.

Vous n'avez pas à écrire de code.

Objectif

L'objectif de cet exercice est d'évaluer votre capacité à concevoir un processus de fiabilisation de données, à distinguer les traitements déterministes des traitements sémantiques et à positionner un LLM de manière pertinente dans une chaîne de traitement automatisée.