
Fiabilisation du catalogue produit

Cas pratique d'automatisation

Bechir Yengui • Exercice technique, Solutions Engineer, ULTY • 11 août 2026

Le principe


Je traite les problèmes du plus simple au plus délicat, en trois étages, chacun déblayant le terrain pour le suivant :

- **Les règles** vérifient tout ce qui se calcule ou se teste : checksum d'EAN, URL qui répond, hiérarchie complète. Rapides, gratuites, même résultat sur la même entrée.
- **Le LLM** ne reçoit que ce que les règles n'ont pas résolu, là où il faut comprendre le texte : libellé caisse abrégé, quasi-doublons, catégorie manquante.
- **L'humain** ne voit que ce que le LLM ne peut pas garantir : les cas à risque fiscal ou réglementaire, et ceux où la confiance est trop basse.

Et un cadrage sur la mesure :

- **La finalité** : des produits publiables. Chez ULTY, une image morte ou une catégorie incohérente finit en produit dépublié, donc en chiffre d'affaires perdu pour le client.
- **Mais ce taux ne note pas le pipeline** : il dépend surtout des données sources (aucun traitement n'invente une image absente), et le maximiser à tout prix pousserait à deviner, ce qui est l'inverse de la prudence défendue ici.
- **J'évalue le pipeline sur ce qu'il contrôle** : zéro correction automatique erronée, et une charge de revue humaine qui baisse à chaque dépôt. Le taux de publiables reste l'indicateur d'impact côté client.
- **Rien ne se perd** : chaque produit non publiable ressort avec la raison précise de son blocage. Les 1 278 lignes sans image ne sont pas un échec du pipeline, c'est la liste de travail qu'il remet au fournisseur.

Le pipeline en un schéma



En bleu, les règles ; en orange, le sémantique ; en vert, le seul endroit où un humain intervient. La flèche en pointillés est la boucle de retour : chaque correction validée est mémorisée, donc le pipeline coûte moins cher chaque jour. **Un point d'ordre, délibéré : le LLM passe AVANT la résolution des quasi-doublons.** « DOLIP 1G CPR » et « DOLIPRANE 1 G » désignent le même produit, mais leurs caractères ne se ressemblent pas assez pour qu'une similarité textuelle les rapproche sans fusionner en même temps des produits distincts. Une fois réécrits par le LLM en libellés développés, les deux convergent et le rapprochement flou les retrouve. L'ordre inverse laisserait ce type de paires non détecté.

Ce que le profilage du fichier a révélé

Un pipeline se conçoit sur les données réelles, pas sur des hypothèses. Chaque constat ci-dessous vient du fichier et a changé une décision de conception.

Ce que le fichier contient vraiment	Ce que ça change
343 libellés distincts pour 10 000 lignes, zéro doublon exact (ni <code>id_produit</code> ni EAN). Le cola s'écrit de 36 façons (« COKA COLA ZERO 1 L », « COCACOLA Z 100CL », « COC COL ZER 1L »...), chaque variante avec un EAN différent.	Le sujet central est la résolution d'entités ; l'EAN ne peut pas servir d'ancre.
Les 10 000 taux de TVA sont tous légaux , et pourtant 394 sont incohérents avec le produit (whisky à 10, 5,5 ou 2,1 %, « LESS. LIQUIDE 200CL » à 2,1 %).	Le contrôle « taux légal » capture zéro anomalie ; seul le croisement catégorie → taux détecte.
768 codes ratent le checksum : 386 réparables par complétion, 249 par retrait de zéros de tête, 133 codes PLU de 3 à 5 chiffres. Plus 1 438 préfixes GS1 internes et 1 300 vides.	Un échec de checksum exige un diagnostic, pas un rejet : réparable, interne à router, ou faux à signaler.
118 lignes en mojibake (« CAFÃ% PUR ARAB 250 GR »), 153 suffixes marketing collés (« WHISKY 40%NEW FORMULA »).	Réparés / détachés à l'ingestion, sinon la déduplication compare du bruit.
1 278 lignes sans image exploitable (800 vides, 400 /missing/, 78 malformées) et 86 URLs réparables (<code>http://</code> , <code>www.</code>).	Près de 13 % du catalogue invendable en l'état : réparer par règle, vérifier par HEAD, signaler le reste.
250 niveaux 3 sans niveau 2, 400 hiérarchies incomplètes, 554 taxonomies contredisant le nom (« PAMPERS BABY DRY 4 » en LIQUIDE, « WHISKY ECOSSAIS 70 CL » en LIQUIDE).	Le contrôle de hiérarchie ne suffit pas : croiser taxonomie et nom, et router en revue humaine.

Les décomptes reposant sur une table de règles (mots-clés, correspondance catégorie → taux) dépendent de cette table ; elle est versionnée avec le code et rejouée en CI.

Les étapes

1. Ingestion et normalisation technique. On remet d'abord le fichier d'aplomb : forcer l'UTF-8 et réparer le mojibake, neutraliser le BOM, parser le CSV proprement, retirer les espaces, vérifier le schéma. Deux pièges ont été mesurés à cette étape. Le premier : réparer le mojibake ne suffit pas. Une fois « ÉPICERIE SUCREE » réparé avec son accent, il ne correspond plus à « EPICERIE SUCREE » du référentiel, qui s'écrit sans accent. Il faut donc canonicaliser chaque valeur contre l'orthographe de référence après réparation, faute de quoi 104 lignes atterrissent dans une catégorie qui n'existe pas. Le second piège : les suffixes marketing collés au libellé sans espace, comme « WHISKY 40%NEW FORMULA ». Ils sont détachés ici, parce que s'ils restent collés, ils faussent le calcul de similarité de l'étape 5b.

2. Contrôles champ par champ. Pour l'**ean**, la clé de contrôle d'abord : le dernier chiffre se calcule à partir des autres, et s'il ne retombe pas juste, le code est faux. Mais un échec de checksum mérite un diagnostic, pas un rejet. Le tri des 10 000 codes du fichier totalise exactement 10 000, ce qui garantit qu'aucun n'est compté deux fois ni oublié. Il donne ceci. 6 494 codes sont valides tels quels. 386 redeviennent valides une fois complétés à la bonne longueur (« 789 » devient « 00000789 ») et 249 une fois débarrassés de zéros de tête en trop ; ces corrections restent tracées dans l'audit trail et réversibles, car un checksum peut retomber juste par hasard une fois sur dix. 1 438 codes portent un préfixe GS1 20 à 29, une plage que le standard réserve à l'usage interne (produits pesés, marques de distributeur), et 133 codes ne font que 3 à 5 chiffres : ce sont des codes PLU ou balance. Ces deux familles sont légitimes, donc routées comme codes internes au lieu d'être « corrigées ». 1 300 codes sont vides, ce

qui est un état normal pour des produits pesés ou de la restauration, pas une anomalie. Et zéro code est réellement corrompu sur ce fichier ; la branche « signalé, jamais deviné » existe dans le pipeline pour ce cas. Pour l'**url_image**, on vérifie que l'URL est bien formée, puis une requête HEAD asynchrone confirme que l'image répond sans la télécharger. Une image non vérifiée n'est pas une image morte : le pipeline distingue les deux, et un produit dont l'image n'a pas été contrôlée n'est jamais déclaré publiable. Pour la **tva**, le taux doit appartenir aux taux légaux français (2,1 ; 5,5 ; 10 ; 20 %). Ce contrôle est nécessaire mais insuffisant, comme le montre l'étape 3. Pour la **taxonomie**, la hiérarchie doit être complète, les valeurs doivent appartenir au référentiel, et les variantes d'écriture d'une même catégorie sont rapprochées (« CRÈMERIE » et « CREMERIE » désignent la même chose).

3. Cohérence entre les champs. On croise ensuite les champs entre eux. La taxonomie est confrontée au nom par mots-clés : un whisky classé en LIQUIDE est une contradiction franche, et le fichier en contient 554. La TVA est confrontée à la catégorie par une table de correspondance (alcools et entretien à 20 %, alimentaire à 5,5 %), qui relève 394 lignes. Une précaution importante : ce contrôle TVA n'est appliqué que si la taxonomie ne contredit pas déjà le nom. Sans ce garde-fou, une même ligne mal classée déclencherait deux anomalies pour un seul défaut, et la charge de revue humaine gonflerait artificiellement. Dans tous les cas, on signale, on ne corrige jamais en douce. J'ai aussi testé le croisement de l'EAN avec une base publique : sur six EAN valides tirés du fichier, un seul existe dans Open Food Facts, et c'est une fausse correspondance (des tomates devenues guimauve). Les EAN de ce fichier sont synthétiques ; ce branchement attendra de vrais codes-barres.

4. Enrichissement par LLM. C'est là qu'il apporte le plus : réécrire les libellés caisse (« CAFE MLU 250G » devient « Café moulu 250 g »), compléter une taxonomie manquante à partir du nom, extraire des attributs structurés comme la marque et la contenance. Trois garde-fous encadrent l'appel. La sortie est contrainte en JSON avec un schéma imposé, jamais du texte libre. La taxonomie de référence est fournie dans le prompt, pour que le modèle choisisse parmi les catégories existantes au lieu d'en inventer. Et un score de confiance est demandé en retour : il alimente l'aiguillage de l'étape 6. S'y ajoute une règle d'économie : je lui envoie les libellés distincts, pas les lignes, soit 273 appels de contenu au lieu de 10 000, un facteur 37. Les réponses sont mises en cache libellé par libellé, si bien qu'au dépôt suivant du même magasin, seuls les libellés jamais vus sont facturés.

5. Résolution d'entités. Les doublons exacts se règlent par comparaison directe après normalisation. Ce fichier n'en contient aucun : toute la difficulté est dans les quasi-doublons, et je la traite en deux temps. D'abord le *blocking* : on ne compare que les fiches d'une même classe, définie par la catégorie feuille et la contenance. Cela ramène 37 128 paires potentielles à 2 507 comparaisons utiles. La contenance est normalisée en volume avant regroupement, pour que « 1 L » et « 100CL » se rencontrent, mais elle reste une barrière dure : un produit en 1 L et le même en 33 cl ont des libellés très proches et sont pourtant deux références distinctes. Ensuite la similarité textuelle, calculée avec RapidFuzz sur le libellé enrichi par le LLM et non sur le libellé brut. Au-dessus de 0,86 on fusionne, en dessous de 0,72 on sépare. Entre les deux, on ne fusionne pas, et c'est délibéré : une fusion à tort est invisible et irréversible, tandis qu'un doublon restant se voit et se corrige. Mesuré sans l'étape LLM, le fichier passe de 343 écritures à 273 libellés réels, puis à 71 golden records ; c'est un plancher, car l'enrichissement actif fait encore converger les libellés. La fusion elle-même suit des règles de *survivorship* écrites : on garde le libellé le plus complet, l'EAN qui passe le checksum, l'image qui répond et la taxonomie la plus profonde. Un désaccord de TVA entre fiches fusionnées part en revue, il n'est jamais tranché d'autorité. Enfin, les 10 000 lignes ne disparaissent pas : chaque ligne garde son identifiant magasin et son rattachement à la fiche, pour qu'une information comme « stock de tel code = 12 » reste rattachée au bon produit.

6. Score et aiguillage. Chaque produit ressort avec un statut : validé, corrigé automatiquement, à revoir ou à compléter. Le seuil dépend du champ. Une reformulation de libellé à haute confiance passe seule ; un changement de TVA ne passe jamais seul, quel que soit le score.

7. Validation humaine, en décisions groupées. N'y arrivent que les propositions du LLM peu sûres, les contradictions non résolues, la création d'une nouvelle catégorie et tout ce qui touche à la TVA. Grâce à la résolution d'entités, l'humain ne relit pas des lignes une par une : il tranche des décisions

groupées. Et chaque décision validée enrichit le cache, les règles et la table catégorie vers TVA, donc la même question n'est jamais posée deux fois.

La vie d'un produit : le whisky

945 lignes du fichier décrivent une seule bouteille, sous **29 libellés** (« WHISKY ECOSSAIS 70 CL », 229 lignes ; « WHISKY 40 70CL », 223 ; « WHISKY BTL 0.7L », 215...). L'étape 1 détache « 40%NEW FORMULA » ; l'étape 2 signale 127 EAN vides, 93 URLs vides, 44 images /missing/ ; l'étape 3 relève 32 lignes hors des 20 % attendus pour un alcool (15 à 10 %, 9 à 5,5 %, 8 à 2,1 %) et 17 taxonomies contredisant le nom. Le LLM ne voit que les 29 libellés et propose « Whisky écossais 40% 70 cl » ; le blocking les regroupe en un bloc, la similarité confirme, le golden record retient la taxonomie majoritaire BOISSONS (835 lignes sur 945). L'humain reçoit **une seule décision groupée** : « 32 lignes ont une TVA $\neq$ 20 % : appliquer 20 % partout ? ». Un clic, l'audit trail garde la trace, la règle entre dans la table. **Bilan : 945 lignes, 1 fiche, 1 décision humaine, 945 rattachements conservés.**

Ce qu'on corrige seul, ce qu'on signale

Anomalie	Traitement	Correction automatique ?
Encodage cassé (mojibake), BOM, espaces	Règles	Oui, déterministe
Accent réparé absent du référentiel	Règles (canonicalisation)	Oui, contre l'orthographe de référence
URL au schéma tronqué (http://, www.)	Règles	Oui ; les URLs mortes sont signalées
Image non vérifiée	Règles	Non : distinguée d'une image morte, bloque la publication
EAN à compléter ou à dézéroter	Règles (re-checksum)	Oui ; tracé et réversible
Code PLU ou préfixe GS1 interne	Règles	Routé comme code interne, pas « corrigé »
EAN irréparable	Règles	Signalé, jamais deviné
TVA hors liste légale	Règles	Signalé
TVA légale mais incohérente avec le produit	Règles croisées + humain	Signalé, jamais fixé seul
Doublons exacts	Règles	Oui, après normalisation
Quasi-doublons	Blocking + RapidFuzz sur libellé enrichi	Fusionné au-dessus du seuil haut ; la zone grise reste séparée
Libellé caisse abrégé	LLM	Oui, si le score dépasse le seuil
Taxonomie manquante	LLM	Proposé
Taxonomie contredisant le nom	Règles + humain	Signalé

Où le LLM aide, où il ne décide pas

Ma règle tient en une phrase : le LLM propose, il ne décide jamais seul sur un champ à risque. Pour la TVA, je vais plus loin. Le champ n'est pas soumis au modèle du tout : le prompt le lui interdit et la valeur ne lui est jamais montrée. Un modèle ne peut pas se tromper sur une donnée qu'il ne voit pas.

Prenons un cas réel du fichier pour comprendre pourquoi la revue humaine n'est pas un aveu d'échec. « WHISKY ECOSSAIS 70 CL » est classé en LIQUIDE. Un des deux champs ment forcément, mais savoir lequel exige une information que la machine n'a pas : le produit physique réel. Le LLM dirait « whisky » avec 90 % de confiance, et il aurait probablement raison. Le problème est que les deux erreurs possibles n'ont pas le même coût. Si le nom est faux et qu'on reclasse quand même en SPIRITUEUX,

on impose une vérification d'âge et une TVA à 20 % pour vendre du détergent. Si le nom est juste et qu'on garde LIQUIDE, on vend de l'alcool sans restriction d'âge et à la mauvaise TVA, ce qui est une infraction fiscale et réglementaire chez le client. Face à un pari aussi asymétrique, on ne parie pas. Le LLM propose sa correction avec son score, et un humain valide en un clic grâce aux décisions groupées.

Cette frontière entre automatique et humain n'est pas figée, elle dépend des preuves disponibles. Le jour où un référentiel externe fiable confirme l'EAN et que le nom concorde, la taxonomie isolée pourra se corriger automatiquement, parce que deux sources s'accorderont contre une. Ce cas basculera alors vers les règles, pas vers le LLM : interroger une base de données est un traitement déterministe, alors que demander à un LLM de retrouver de mémoire le produit derrière un EAN serait le cas d'école de l'hallucination. Deux décisions restent à l'humain quoi qu'il arrive, parce qu'elles engagent le client : la TVA et la création de catégories. À l'inverse, certaines tâches sont un contre-emploi pour un LLM : vérifier une clé de contrôle d'EAN est de l'arithmétique, pas de la compréhension, et une règle le fait parfaitement. Bien positionner un LLM, c'est autant savoir où il n'a rien à faire que là où il excelle.

Le LLM est utile pour	Le LLM ne tranche pas seul
Nettoyer les libellés abrégés	Fixer un taux de TVA (champ non soumis)
Compléter une taxonomie manquante	Régler une incohérence taxonomie ↔ nom
Extraire des attributs (marque, format)	Créer une nouvelle catégorie
Rendre les quasi-doublons comparables	Valider un checksum (rôle des règles)
	Tout cas où le score est trop bas

Coût et passage à l'échelle

Le coût du LLM est affiché par traitement (modèle, appels réels, part servie par le cache, jetons, dollars) et tenu par trois leviers : la déduplication avant appel (273 libellés au lieu de 10 000 lignes), le cache par libellé (5 % de nouveautés au dépôt suivant = 5 % refacturés, contre 100 % avec un cache par lot), et le traitement asynchrone à moitié prix pour les dépôts nocturnes. Un plafond de dépense coupe l'appel au LLM sans arrêter le reste du pipeline.

À l'échelle réelle d'ULTY, avec des centaines de magasins, la logique ne change pas mais la résolution d'entités devient centrale : l'EAN sert d'ancre quand il est fiable, le sémantique prend le relais quand il ne l'est pas (codes internes, EAN manquants), exactement les cas que le pipeline aura appris à reconnaître. Et le cache prend tout son sens : « COCA COLA ZERO 1L » chez deux enseignes, c'est le même travail d'enrichissement, payé une fois.